第一章：什么是学习?

机器学习与深度学习：从小学生到大师

2026-03-24

第一章：什么是学习?

> *在教机器之前，我们先想想：你自己是怎么学会一件事的?*

1.1 从一个问题开始

假设你今天第一次吃苹果。

妈妈递给你一个红红圆圆的东西，说：“这是苹果，甜甜的，可以吃。”

你咬了一口，确实是甜的。

第二天，你又看到一个红红圆圆的东西，妈妈还没开口，你就说：“这是苹果！”

这就是学习。

你看了（观察）、吃了（体验）、记住了（存储）、下次认出来了（预测）。

机器学习的本质，和这一模一样。

1.2 机器学习的两个经典定义

在深入了解之前，让我们看看两个最重要的定义。

定义一：Arthur Samuel (1959)

“Machine Learning is the field of study that gives computers the ability to learn without being explicitly programmed.”

（机器学习是让计算机在没有被明确编程的情况下拥有学习能力的领域。）

背景故事：Arthur Samuel在IBM工作时，写了一个下跳棋的程序。这个程序和自己下了成千上万盘棋，通过观察什么样的棋局容易赢、什么样的容易输，**自己学会了下棋**。最终，这个程序下棋的水平超过了Samuel本人。

关键点： - 不需要人类告诉机器每一步怎么走 - 机器从**经验**中学习 - 这和人类学下棋是一样的：多下、多总结、水平提高

定义二：Tom Mitchell (1997) —— 更形式化的定义

“A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P, if its performance at tasks in T, as measured by P, improves with experience E.”

（如果一个计算机程序在某类任务T上的性能P，随着经验E的提高而提高，那么它就称为从经验E中学习。）

用跳棋程序的例子拆解： - **E（Experience，经验）**：和自己下了成千上万盘棋 - **T（Task，任务）**：下跳棋 - **P（Performance，性能）**：获胜的概率

用邮件分类的例子拆解： - **E**：看了你标记的上千封垃圾/正常邮件 - **T**：判断新邮件是否是垃圾邮件 - **P**：正确分类的百分比

两个定义的关系

定义	特点	适用场景
Arthur Samuel	直观、易懂	向初学者解释什么是ML
Tom Mitchell	形式化、精确	学术研究、定义问题

本书的立场：我们用Samuel的定义建立直觉，用Mitchell的定义分析问题。两者缺一不可。

1.3 人类学习 vs 机器学习

人类学习	机器学习
看很多猫的图片	输入很多猫的图片数据
大脑自动找特征：尖耳朵、胡须、毛茸茸	算法自动找特征：边缘、纹理、形状
下次看到类似的东西，说”这是猫”	下次输入新图片，输出”猫”
认错了会被纠正：“不对，这是老虎”	预测错了会调整参数（学习）

关键洞察：人类有大脑，机器有数学模型。两者都是”从例子中找规律”。

1.4 机器学习的三大类型

类型一：监督学习（Supervised Learning）

生活比喻：有老师教

你做作业，老师批改，告诉你哪里错了，你改正。

机器学习版本： - 给机器看很多”问题+答案”的对子 - 比如：图片（问题）+ “这是猫”（答案） - 机器学着从问题推答案 - 学会后，给新图片，它能自己回答

例子： - 识别垃圾邮件（邮件内容 → 是/否垃圾邮件） - 预测房价（房子信息 → 价格） - 识别手写数字（图片 → 0-9数字）

类型二：无监督学习（Unsupervised Learning）

生活比喻：自学，没有标准答案

给你一堆水果：苹果、香蕉、橙子混在一起。 没人告诉你哪个是什么，但你自己会分类：红红的放一起，弯弯的放一起。

机器学习版本： - 给机器一堆数据，但没有”正确答案” - 机器自己找规律、分组、发现结构

例子： - 客户分群（把相似购买行为的客户自动分组） - 文章主题分类（自动发现文章在讲什么主题） - 异常检测（找出和大多数不一样的数据）

类型三：强化学习（Reinforcement Learning）

生活比喻：试错学习

学骑自行车： - 往左倒了，你往右修正 → 结果好（没摔）→ 记住这个动作 - 往右倒了，你继续往右 → 结果坏（摔了）→ 下次不这么做

机器学习版本： - 机器（智能体）在一个环境中做动作 - 做得好得到奖励，做得差得到惩罚 - 目标是最大化长期奖励

例子： - AlphaGo下围棋 - 自动驾驶汽车 - 游戏AI（打超级玛丽、星际争霸）

1.4 机器学习 = 找函数

这是最核心的观点，务必记住：

> ***机器学习，就是让机器自动找出一个函数。***

```
输入(x) → [神秘函数 f] → 输出(y)
```

- **监督学习**：找 `f`，使得 `f(猫的图片) = "猫"`
- **无监督学习**：找 `f`，使得 `f(一堆数据) = "分组结果"`
- **强化学习**：找 `f`，使得 `f(游戏画面) = "最优动作"`

我们后面所有的算法，都是在说：怎么找到这个 `f`。

1.5 学习的四要素

任何机器学习问题，都有这四个要素：

1. 数据（Data）

学习的原材料。

比如手写数字识别： - 70000张28×28像素的图片 - 每张都标注了是0-9的哪个数字 - 就像70000道”看图认数字”的练习题

经典数据集（我们后面会反复用到）： - **MNIST**：手写数字，机器学习界的”Hello World” - **Iris**：鸢尾花，3种花的分类，150个样本 - **Boston Housing**：波士顿房价预测 - **CIFAR-10**：10类彩色小图片

2. 模型（Model）

猜测的规律的形式。

就像你猜测”房价和面积的关系”： - 可能是直线：`房价 = k × 面积 + b` - 可能是曲线：`房价 = a × 面积² + b × 面积 + c` - 可能是更复杂的形状

模型就是”函数的形状”，我们要从中选一个（或组合多个）。

3. 损失函数（Loss Function）

衡量”猜得有多烂”。

- 你猜房价100万，实际是150万，差了50万
- 损失就是50万（简化版）

> ***机器的目标：让损失越小越好***

这就像考试：损失是你的错题数，目标是错题越少越好。

4. 优化算法（Optimizer）

如何改进猜测。

知道猜得烂还不够，还要知道怎么改： - 是把斜率调大一点？ - 还是把截距调小一点？ - 调多少？

优化算法就是回答：“看到错误后，参数该怎么调整？”

1.6 第一个程序：Hello, Machine Learning!

让我们写一段最简单的代码，感受一下。

我们不训练模型，只是演示”输入 → 处理 → 输出”的流程。

```
(#cb2-1)# hello_ml.py
(#cb2-2)# 我们的第一个机器学习程序
(#cb2-3)
(#cb2-4)import numpy as np
(#cb2-5)
(#cb2-6)# ====================
(#cb2-7)# 第1步：准备数据
(#cb2-8)# ====================
(#cb2-9)# 特征：学习时间（小时）
(#cb2-10)# 标签：考试分数
(#cb2-11)study_hours = np.array([1, 2, 3, 4, 5, 6, 7, 8, 9, 10])
(#cb2-12)scores = np.array([55, 60, 65, 70, 75, 80, 85, 90, 95, 98])
(#cb2-13)
(#cb2-14)print(" 学习数据：")
(#cb2-15)print("学习时间:", study_hours)
(#cb2-16)print("考试分数:", scores)
(#cb2-17)print()
(#cb2-18)
(#cb2-19)# ====================
(#cb2-20)# 第2步：假设一个模型
(#cb2-21)# ====================
(#cb2-22)# 我们猜测：分数 = 5 × 小时 + 50
```

```
(#cb2-23)# （先随便猜，后面学怎么自动找最好的）
(#cb2-24)
(#cb2-25)def predict(hours, weight=5, bias=50):
(#cb2-26)    """
(#cb2-27)    我们的简单模型
(#cb2-28)    weight: 权重（每小时值多少分）
(#cb2-29)    bias: 偏置（基础分）
(#cb2-30)    """
(#cb2-31)    return weight * hours + bias
(#cb2-32)
(#cb2-33)# ====================
(#cb2-34)# 第3步：预测
(#cb2-35)# ====================
(#cb2-36)print(" 用模型预测：")
(#cb2-37)for h in [2, 5, 8]:
(#cb2-38)    prediction = predict(h)
(#cb2-39)    print(f"  学习{h}小时 → 预测分数: {prediction}")
(#cb2-40)print()
(#cb2-41)
(#cb2-42)# ====================
(#cb2-43)# 第4步：计算误差（损失）
(#cb2-44)# ====================
(#cb2-45)def mean_squared_error(predictions, actual):
(#cb2-46)    """均方误差：预测值和真实值差的平方的平均"""
(#cb2-47)    return np.mean((predictions - actual) ** 2)
(#cb2-48)
(#cb2-49)# 用我们的模型预测所有数据
(#cb2-50)predictions = predict(study_hours)
(#cb2-51)loss = mean_squared_error(predictions, scores)
(#cb2-52)
(#cb2-53)print(f" 当前模型的误差（损失）: {loss:.2f}")
(#cb2-54)print()
(#cb2-55)
(#cb2-56)# ====================
(#cb2-57)# 第5步：可视化
(#cb2-58)# ====================
(#cb2-59)print(" 数据可视化（文本版）：")
(#cb2-60)print("学习小时 | 真实分数 | 预测分数 | 误差")
(#cb2-61)print("-" * 45)
(#cb2-62)for i in range(len(study_hours)):
(#cb2-63)    h = study_hours[i]
(#cb2-64)    real = scores[i]
(#cb2-65)    pred = int(predictions[i])
(#cb2-66)    err = real - pred
(#cb2-67)    print(f"    {h:2d}    |    {real:2d}    |    {pred:2d}    |
{err:+3d}")
```

运行结果：

```
 学习数据：
学习时间: [ 1  2  3  4  5  6  7  8  9 10]
考试分数: [55 60 65 70 75 80 85 90 95 98]

 用模型预测：
  学习2小时 → 预测分数: 60
  学习5小时 → 预测分数: 75
  学习8小时 → 预测分数: 90

 当前模型的误差（损失）: 2.30

 数据可视化（文本版）：
学习小时 | 真实分数 | 预测分数 | 误差
---------------------------------------------
     1    |    55    |    55    |   +0
     2    |    60    |    60    |   +0
     ...
```

你刚才做了什么： 1. 准备了数据（学习时间和分数） 2. 选择了一个模型（线性：分数 = 5×小时 + 50） 3. 做了预测 4. 计算了误差 5. 看到了结果

这就是机器学习的完整流程！后面我们会学：怎么自动找到最好的 `weight` 和 `bias`，而不是靠猜。

1.7 本章小结

核心概念

概念	一句话解释
机器学习	让机器从数据中自动找规律
监督学习	有正确答案的学习（像有老师教）
无监督学习	自己找规律的学习（像自学）
强化学习	试错中学习（像学骑车）
模型	猜测的规律的形式（一个函数）
损失	猜得有多烂（误差大小）
优化	怎么改才能猜得更好

关键公式

机器学习的本质：

$$\text{找到 } f\text{，使得 } f(x) \approx y$$

费曼理解检查

合上书本，试着回答： 1. 如果你要教一个5岁小孩什么是机器学习，你会怎么说？ 2. 监督学习和无监督学习有什么区别？举一个生活中的例子。 3. 为什么说”机器学习 = 找函数”？

1.8 费曼学习法实战：如何检验你真的懂了

本书采用费曼学习法编写。每章结束时，用这个流程检验自己：

四步检验法

第一步：选概念 选一个本章核心概念（比如”监督学习”或”损失函数”）。

第二步：讲给8岁小孩听

不好的解释：> “监督学习是一种利用带标签数据集进行训练以建立输入输出映射关系的机器学习方法。”

好的解释（费曼式）：> “监督学习就像老师批改作业。你做题（输入），老师告诉你对错（答案），你改正。机器也一样，看很多’问题+答案’，学会怎么从问题想到答案。”

第三步：找盲区

问自己：- 我刚才用了什么专业术语？- 如果小孩问”为什么老师知道答案”，我能答吗？- 哪里讲得含糊不清？

找到这些盲区，回到正文重新学习。

第四步：创造类比

用你自己的比喻：- 监督学习 = 学车（教练指导）- 无监督学习 = 自己学骑自行车（试错）- 强化学习 = 打游戏（得分反馈）

记住费曼的话：如果你不能简单地解释它，说明你还没真正理解它。

1.9 本章小结

核心概念

概念	一句话解释
机器学习	让机器从数据中自动找规律（Arthur Samuel: 无需显式编程；Tom Mitchell: E+T+P框架）
监督学习	有正确答案的学习（像有老师教）
无监督学习	自己找规律的学习（像自学）
强化学习	试错中学习（像学骑车）
模型	猜测的规律的形式（一个函数）
损失	猜得有多烂（误差大小）
优化	怎么改才能猜得更好

关键公式

机器学习的本质：

$$\text{找到 } f\text{，使得 } f(x) \approx y$$

Tom Mitchell的形式化定义：

$$\text{Performance}(T) \text{ improves with } E\text{, measured by } P$$

费曼理解检查

合上书本，试着回答： 1. 如果你要教一个5岁小孩什么是机器学习，你会怎么说？（不能用”算法”、“数据”这些词） 2. Arthur Samuel和Tom Mitchell的定义有什么区别？什么时候用哪个？ 3. 为什么说”机器学习 = 找函数”？ 4. 用E/T/P框架分析：垃圾邮件过滤器的E、T、P分别是什么？

1.10 视觉总结

图1-1：机器学习的大图景（文字描述）

```
┌──────────────────────────────────────────────────────────┐
│                    机器学习 (Machine Learning)            │
│              "让计算机从经验中学习，无需显式编程"          │
└──────────────────────────────────────────────────────────┘
                        │
                        │
          ┌─────────────┼─────────────┐
          ↓             ↓             ↓

    ┌─────────┐   ┌─────────┐   ┌─────────┐
    │ 监督学习 │   │ 无监督  │   │ 强化学习 │
    │Supervised│   │Learning │   │Reinforce│
    │Learning │   │         │   │  ment   │
    └────┬────┘   └────┬────┘   └────┬────┘
         │             │             │
    "有老师教"     "自己发现"     "试错学习"
    分类/回归       聚类/降维       游戏/机器人
```

图1-2：机器学习的四个要素（文字描述）

```
          ┌──────────────────┐
          │     数据 Data     │
          │   (学习的原材料)   │
          └──────────┬───────┘
                     ↓
          ┌──────────────────┐
          │     模型 Model    │
          │  (函数的形状)     │
          └──────────┬───────┘
                     ↓
          ┌──────────────────┐
          │  损失函数 Loss    │
          │  (猜得有多烂)     │
          └──────────┬───────┘
                     ↓
          ┌──────────────────┐
          │   优化器 Optimizer│
          │  (如何改进)       │
          └──────────────────┘
```

图1-3：Tom Mitchell的E/T/P框架（文字描述）

```
┌──────────────────────────────────────────────────────────┐
│  垃圾邮件过滤器示例                                        │
├──────────────────────────────────────────────────────────┤
│                                                          │
│  E (Experience/经验)                                      │
│  └── 看了10,000封你标记为"垃圾"或"正常"的邮件              │
│                                                          │
│  T (Task/任务)                                            │
│  └── 判断新邮件是否是垃圾邮件                              │
│                                                          │
│  P (Performance/性能)                                     │
│  └── 正确分类的百分比（比如95%）                           │
│                                                          │
│  学习 = P随着E的增加而提高                                 │
│                                                          │
└──────────────────────────────────────────────────────────┘
```

1.11 练习

练习1：分类

判断以下问题是监督学习、无监督学习还是强化学习：

1. 根据邮件内容判断是否是垃圾邮件
2. 把新闻自动分类到体育、科技、娱乐等板块
3. 训练机器人走迷宫
4. 根据历史数据预测明天股票涨跌
5. 把客户按购买习惯分成不同群体

练习2：费曼挑战

用费曼四步法，向一个8岁小孩解释”机器学习就是找函数”这个概念。写下来，确保没有专业术语。

练习3：创造类比

为以下概念创造你自己的类比（不能用书中的）： - 数据 - 模型 - 损失函数 - 优化算法

练习4：代码拓展

修改 `hello_ml.py`： 1. 尝试不同的 `weight` 和 `bias`，看看哪个误差更小 2. 添加新的数据点（比如学习11小时，分数99） 3. 打印出”最佳猜测”的参数组合 4. **挑战**：写一个循环，自动尝试不同的参数，找到误差最小的组合

参考文献

[1] Mitchell, T. M. Machine Learning. McGraw-Hill, 1997. > 机器学习的经典教材，定义了”如果程序在某任务上的性能随经验提高，则说它从经验中学习”。

[2] 周志华. 机器学习. 清华大学出版社, 2016. > 国内最通俗易懂的机器学习入门书，西瓜书的例子非常生动。

[3] LeCun, Y., Bengio, Y., & Hinton, G. Deep learning. Nature, 2015, 521(7553), 436-444. > 深度学习三巨头的综述文章，阐述机器学习的基本范式。

下章预告

第二章：机器如何”看见”数据

我们将学习： - 什么是特征、标签、样本 - 数据有哪些类型（数字、文字、图片） - 如何把现实世界变成机器能理解的数字 - 数据预处理的基本操作

记住：垃圾进，垃圾出。好的数据是成功的一半。

本章完

更新时间: 2026-03-24
作者: [待填写]
版本: v1.0